

# Hoja de fórmulas:

$x^*$  Candidato a mín Local

← **Pasos:** (CNPO)  
 i)  $\nabla f(x) = 0$  find  $x^*$   
 ii)  $d' \nabla^2 f(x^*) \geq 0$  ó  $= 0$ .  
 (Vector  $(d_1, \dots, d_n)$   
 $n \rightarrow$  num. variables en  $f(x)$ )  
 Si  $x^*$  cumple es  
 Candidato a mín. local  
 ↓  
 Debe cumplir Vd.  
 y  $d \neq 0$ .

$$\text{Hessiano} = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}$$

2x2: 0 Inversa  $\frac{1}{ad-bc} \begin{pmatrix} d & -b \\ c & a \end{pmatrix}$   
 0 det.  $ad-bc$

3x3: 0 Det (Sarrus)  $\begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix} \rightarrow -\pi$

0 Inversa  $A^{-1} = \frac{1}{|A|} \text{Adj}(A^t)$   
 $|A| < \det(A)$  (Si es 0 no invertible)

$\text{Adj}(A^t) = A_{ij} \Rightarrow (-1)^{i+j} \det(\text{menor}(A_{ij}))$

$x^*$  mín Local.

← **Pasos:** (CNPO) →  $x \in \text{frontera}$  (Si es interior solo hacer 1,2)  
 i)  $H(x)$  def Positiva o Semi  
 ii)  $d' \nabla f(x^*) = 0$   
 iii)  $d' H(x^*) d \geq 0$

$J = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$   
 Se evalúa en los Ptos Críticos  
 0  $\det(a) \geq 0$  Semidef +  
 0  $\det(a, b) \geq 0$  Semidef +  
 0  $\det(a, b, c) \geq 0$  Semidef +  
 Si todas las evaluaciones son  $\geq 0$  es Semiposi  
 $(A - \lambda I)$   $> 0$  es def Posi

$x^*$  es mín estricto ← **Pasos:** (CSSO) (Puntos interiores)

i)  $\nabla f(x^*) = 0$   
 ii)  $H(x^*)$  es def Positiva

**Conjunto Convexo:**  $\cup$

$\mathcal{U} \subset \mathbb{R}^n$ ,  $\mathcal{U}$  es un conj convexo si  $(\lambda x_1 + (1-\lambda)x_2) \in \mathcal{U}, \forall x_1, x_2 \in \mathcal{U} \text{ y } \lambda \in (0,1)$

**Función Convexa:**  $\max\{f(x), g(x)\}$  es Convexa

$f: \mathcal{U} \rightarrow \mathbb{R}$  es convexa si

$f(\lambda x + (1-\lambda)x) \leq \lambda f(x) + (1-\lambda)f(x) / \forall x, \tilde{x} \in \mathcal{U}, \lambda \in (0,1), \mathcal{U}$  Conj. Convexa

< estrictamente Convexa

**Función Cóncava:**  $\cap$

Con recta si

← **Función Cóncava** si  $f = -g$  es convexa. /  $f$  convexa → Continúa en  $\mathcal{U}$

Una es convexa o cóncava la otra también.

0  $f$  derivable es convexa si  $f(x) \geq f(\tilde{x}) + \nabla f(\tilde{x})'(x - \tilde{x})$

0  $f$  2-derivable  $f$  es convexa (estricta) en  $\mathcal{U}$  si  $H(x)$  es sem-posit  $\forall x \in \mathcal{U}$

0  $f$  2-derivable,  $f$  es cóncava (estricta) en  $\mathcal{U}$  si  $H(x)$  es Semi-negativa  $\forall x \in \mathcal{U}$   
 1 Submatrices  $\rightarrow$

Todo mín-local de  $f$  en  $\mathcal{U}$  (convexo) es mín-global

Toda Convexo es

← **Funciones Quasi-convexas:**  $f: \mathcal{U} \rightarrow \mathbb{R}$  es Quasi-convexa si

$f(\lambda x + (1-\lambda)\tilde{x}) \leq \max\{f(x), f(\tilde{x})\}, \forall x, \tilde{x} \in \mathcal{U}, \lambda \in [0,1]$

Estrictamente

Quasi-Convexa en  $[a,b]$

$\lambda, \mu \in [a,b], \lambda < \mu$

0 Si  $f(\mu) < f(\lambda) \Rightarrow f(\mu) \leq f(z), \forall z \in [\mu, \lambda]$

0 Si  $f(\lambda) < f(\mu) \Rightarrow f(\lambda) \leq f(z), \forall z \in [\lambda, \mu]$

# Algoritmo de selección cuéca:

$\varepsilon = 0.0001$  (Criterio de Parada)

Paso 0: Long. final del int I. ? int inicial  $[a_0, b_0]$ ,  $k=0$   
 $\lambda_0 = a_0 + (1-\alpha)(b_0 - a_0)$ ,  $f(\lambda_0)$   
 $\mu_0 = a_0 + \alpha(b_0 - a_0)$ ,  $f(\mu_0)$

Paso 1:

Si  $b_k - a_k < \varepsilon$  luego

Parar,  $\lambda^* \in [a_k, b_k]$

else

? f  $f(\lambda_k) > f(\mu_k)$  then

Paso 2

else

Paso 3

endif

endif

Paso 2: ( $f(\lambda_k) > f(\mu_k)$ ):

$a_{k+1} = \lambda_k$ ,  $b_{k+1} = b_k$ ,  $\lambda_{k+1} = \mu_k$

$\mu_{k+1} = a_{k+1} + \alpha(b_{k+1} - a_{k+1})$

$f(\mu_{k+1})$ ,  $k = k+1$ , ir al Paso 1.

Paso 3: ( $f(\lambda_k) < f(\mu_k)$ )

$a_{k+1} = a_k$ ,  $b_{k+1} = \mu_k$ ,  $\mu_{k+1} = \lambda_k$

$\lambda_{k+1} = a_{k+1} + (1-\alpha)(b_{k+1} - a_{k+1})$

$f(\lambda_{k+1})$ ,  $k = k+1$ , ir al Paso 1.

## Ajuste Cuadrático:

$i, j \in \{1, 3\}$

$$\hat{X}_k = \frac{b_{23}f(x_1) + b_{31}f(x_2) + b_{12}f(x_3)}{2(a_{23}f(x_1) + a_{31}f(x_2) + a_{12}f(x_3))}$$

$$b_{ij} = x_i^2 - x_j^2, \quad a_{ij} = x_i - x_j$$

Paso 0:  $\varepsilon$ ,  $\text{int}_0 = [x_1, x_2, x_3]$ ,  $k=0$

Paso 1:  $x_1, f(x_1); x_2, f(x_2); x_3, f(x_3)$  /  $\hat{x}_k, f(\hat{x}_k)$

?f  $x_3 - x_1 < \varepsilon$  then

Parar,  $\hat{x}_k \in [x_1, x_3]$

else

?f  $\hat{x}_k > x_2$  then

Ir al Paso 2

else ?f  $\hat{x}_k < x_2$  then

Ir al Paso 3

else ?f  $\hat{x}_k = x_2$  then

Ir al Paso 4

endif

endif

Paso 2: ( $\hat{x}_k > x_2$ )

?f  $f(\hat{x}_k) > f(x_2)$  Luego  $[x_1, x_2, \hat{x}_k]$  } Ir al Paso 1

?f  $f(\hat{x}_k) \leq f(x_2)$  Luego  $[x_1, \hat{x}_k, x_3]$

Paso 3: ( $\hat{x}_k < x_2$ ):

?f  $f(\hat{x}_k) > f(x_2) \Rightarrow [\hat{x}_k, x_2, x_3]$  } Ir al Paso 1

?f  $f(\hat{x}_k) \leq f(x_2) \Rightarrow [x_1, \hat{x}_k, x_2]$

Paso 4: ( $\hat{x}_k = x_2$ )

$$\hat{X}_k = \begin{cases} x_2 + \varepsilon/2 & \text{Si } x_2 - x_1 < x_3 - x_2 \\ x_2 - \varepsilon/2 & \text{Si } x_2 - x_1 > x_3 - x_2 \end{cases} \text{ } \left. \begin{array}{l} \text{Ir al} \\ \text{Paso 1.} \end{array} \right\}$$

$$X_{i+1} = X_i - \frac{f(X_i)}{f'(X_i)}$$

# Newton-Raphson:

Óptimo completo

$$g(\hat{X}) = f'(\hat{X}) = 0$$

min:

$$X_{i+1} = X_i - \frac{g(X_i)}{g'(X_i)}$$

$$= X_i - \frac{f'(X_i)}{f''(X_i)}$$

Paso 0: Pto inicial  $X_0$ ,  $k=0$ , error  $\epsilon = 0.0001$

Paso 1:  $X_{k+1} = X_k - \frac{f'(X_k)}{f''(X_k)}$

if  $|X_{k+1} - X_k| < \epsilon$  then

Stop,  $x^* \in [X_{k+1}, X_k]$

else

Repetir

endif

## Derivada direccional:

$$X_{k+1} = X_k + \lambda d$$

↑  
Nuevo Paso

Si  $f$  diferenciable  $\leftarrow$  Direcciones de descenso: d lo es si  $\exists \delta > 0$

$$f(x, d) = \nabla f(x)' d < 0$$

$$f(x + \lambda d) < f(x), \lambda \in (0, \delta) \rightarrow \text{Con } x \text{ una sola factible } \in \mathbb{R}^n$$

## Método de descenso del gradiente:

$$d = -\frac{\nabla f(x)}{\|\nabla f(x)\|}$$

min  $f(x, a)$

s.a.  $\|d\| = 1$

Paso 0:  $\epsilon > 0$ , Pto inicial buena  $\bar{X}_1, k=1$

Paso 1:

While  $\|\nabla f(X_k)\| > \epsilon$  do

$d_k = -\nabla f(X_k)$

$\lambda_k = \min_{\lambda \geq 0} f(X_k + \lambda d_k)$

$X_{k+1} = X_k + \lambda_k d_k = X_k + \lambda_k (-\nabla f(X_k))$

$k = k+1$

endwhile

Usar búsqueda de líneas

Punto dir

$$D = (X, -\nabla f(x))$$

$$f(x) = \frac{1}{2} x' Q x - b' x$$

↑  
vector

Q def Positiva

$$\nabla f(x) = Qx - b$$

$$H(x) = Q > 0$$

## Convergencia $\rightarrow$ Descenso del gradiente

$$e(x) = \frac{1}{2} (x - x^*)' Q (x - x^*) \quad e(x) = 0 \text{ si } x = x^*, \text{ con } x^* \in \mathcal{N}$$

Si  $x \neq x^* \Rightarrow e(x) > 0$

$$\lambda = \frac{g_k' g_k}{g_k' Q g_k} \quad X_{k+1} = X_k - \frac{g_k' g_k}{g_k' Q g_k} g_k$$

$$\forall x_0 \in \mathbb{R}^n \quad e(X_{k+1}) = \left( \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^2 e(X_k)$$

$\lambda_n, \lambda_1$  val max( $\lambda_n$ ) y min( $\lambda_1$ ) de  $Q \in \text{Autovalores positivos}$   $(A - \lambda I)$

$\gamma = 1 \Rightarrow$  Converge en una iteración de Convergencia

Que hay rápido converge

$$\frac{\lambda_n}{\lambda_1}$$

$$\left( \frac{e(X_{k+1})}{e(X_k)} \right)$$

Factor reducción

## Método de Newton: (Series de Taylor)

$$q(x) = f(X_k) + \nabla f(X_k)' (x - X_k) + \frac{1}{2} (x - X_k)' H(X_k) (x - X_k)$$

↑  
Xo dado - Si no dan tomar (0,0)

Condición necesaria para un mínimo local de  $q(x)$ :  $\nabla q(x) = 0$

$$\nabla q(x) = \nabla f(X_k) + H(X_k) (x - X_k) = 0 \rightarrow \text{Donde } q(x) \text{ Aproxima la función cuadrática}$$

$$H(X_k) x = H(X_k) X_k - \nabla f(X_k)$$

$$x = X_k - H(X_k)^{-1} \nabla f(X_k)$$

$$X_{k+1} = X_k - H(X_k)^{-1} \nabla f(X_k)$$

Sale en una it.

Si H es Singular  $\leftarrow$  Pasa a Si H es indefinida

1. Grad

2. H es indefinida

$X_k$  a partir de  $X_0$

Da un vector

Problemas:

- o Gradiente cercano a 0
- o  $\|X_{k+1} - X_k\|$  cercano a 0
- o  $\|f(X_{k+1}) - f(X_k)\|$  cercano a 0

$\leftarrow$  Aprox lineal en  $X_k$

$$ax^2 + bxy + cy^2 + dx + ey + c$$

$$H = \begin{pmatrix} 2a & b \\ b & 2c \end{pmatrix}$$

$$f(x) = c'x + \frac{1}{2} x' H x$$

Procesos:

i). Definir  $d_1 = (1, 0)$

ii).  $d_1' H x_1 = 0$  obtenemos  $d_1, d_2$  ind. c/ b. Pendo

iii). No dado o termo  $(0,0)$

iv). Usar  $\tilde{x}_j \in \text{óptima}$

## Métodos de direcciones Conjugadas: - arbitraria (1 0)

$H \in \mathbb{R}^{n \times n}$  Simétrica  $\circ \{d_1, \dots, d_n\}$  son veees H-Conjugados si son L.I. def Positiva  
 $\forall d_i' H d_j = 0$  para  $i \neq j$

$$x = x_1 + \sum_{j=1}^n \lambda_j d_j$$

$$\phi(\lambda) = f(x) = f\left(x_1 + \sum_{j=1}^n \lambda_j d_j\right) = c'x_1 + \frac{1}{2} x_1' H x_1 + \sum_{j=1}^n \left( \lambda_j c' d_j + \lambda_j d_j' H x_1 + \frac{1}{2} \lambda_j d_j' H d_j \right)$$

Vector Coeficientes

Óptimo de  $\lambda_j$

$$\frac{\partial \phi(\lambda)}{\partial \lambda_j} = c' d_j + d_j' H x_1 + \lambda_j d_j' H d_j = 0$$

$$\tilde{\lambda}_j = - \frac{c' d_j + d_j' H x_1}{d_j' H d_j}$$