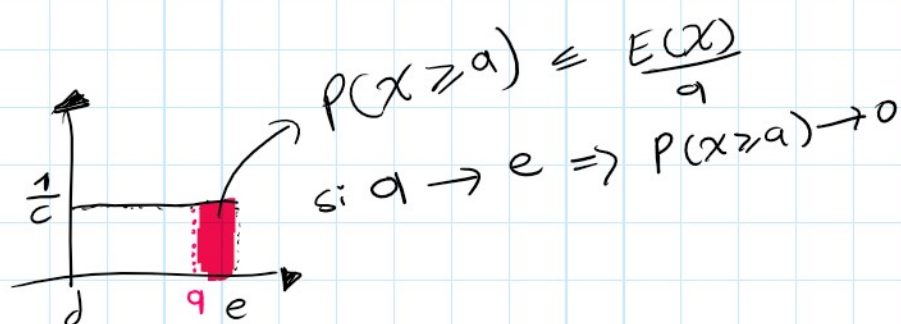


Recuerde: Sea $M_n = \frac{1}{n} \sum_{i=1}^n X_i$, $E(M_n) = \mu$, $\text{Var}(M_n) = \frac{\sigma^2}{n}$

Desigualdad de Markov




Si una v.d. $X \geq 0$, entonces

$$P(X \geq a) \leq \frac{E(X)}{a}, \quad \forall a > 0$$

Desigualdad de Chebyshev

Sea X v.d. con media μ y var σ^2 , entonces

$$P(|X - \mu| \geq c) \leq \frac{\sigma^2}{c^2}, \quad \forall c > 0.$$




Ley débil de los grandes números


Sea $\{X_n\}$ una secuencia de v.d.'s iid con media μ .

$\forall \varepsilon > 0$, se tiene:

$$P(|M_n - \mu| \geq \varepsilon) = P\left(\left|\frac{X_1 + \dots + X_n}{n} - \mu\right| \geq \varepsilon\right) \rightarrow 0, \quad n \rightarrow \infty$$



$n \rightarrow \infty$



Convergencia en probabilidad


Sea $\{V\}$ una secuencia de v.d.'s (No necesariamente indep)

Sea $\{Y_n\}$ una Secuencia de V.a.S (No necesariamente indep).

y Sea $a \in \mathbb{R}$.

$$\text{Si } \forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(|Y_n - a| \geq \varepsilon) = 0$$

$\Rightarrow Y_n$ converge en probabilidad a 'a'.



Teorema del límite Central

Sea $\{X_n\}$ una Secuencia de iid V.a.'s con media μ y Varianza σ^2

$$Z_n = \frac{\left(\sum_{i=1}^n X_i\right) - n \cdot \mu}{\sigma \sqrt{n}}$$

entonces la CDF de Z_n converge a la CDF N.E.

$$\Phi(z) = \frac{1}{\sqrt{2\pi}} \cdot \int_{-\infty}^z e^{-x^2/2} dx$$

Aproximaciones basadas en el TLC

Sea $S_n = \sum_{i=1}^n X_i$ de X_i iid con media μ y var σ^2 , para n grande S_n se puede tratar como normal así:

$$\left. \begin{aligned} P(S_n \leq c) \\ P\left(Z \leq \frac{c - n\mu}{\sigma\sqrt{n}}\right) \approx \Phi(z) \end{aligned} \right\} \text{Normalización}$$

Aproximación de Moivre - Laplace

Una binomial es $S_n = \sum_{i=1}^n X_i$, donde cada X_i es bernoulli iid.

$$E(X_i) = p, \text{ var}(X_i) = p \cdot (1-p).$$

$$P(K \leq S_n \leq L) \approx \Phi\left(\frac{L + \frac{1}{2} - np}{\sqrt{n \cdot p \cdot (1-p)}}\right) - \Phi\left(\frac{K - \frac{1}{2} - np}{\sqrt{n \cdot p \cdot (1-p)}}\right)$$

Ley fuerte de los grandes números

Sea $\{X_n\}$ iid. con media μ , entonces

$$M_n = \frac{\sum_{i=1}^n X_i}{n} \longrightarrow \mu, \text{ con probabilidad 1 es decir:}$$

$$P\left(\lim_{n \rightarrow \infty} \frac{\sum_{i=1}^n X_i}{n} = \mu\right) = 1$$

Muestreo de una población Normal

Sea $\{X_n\}$ una muestra aleatoria de una $N(\mu, \sigma^2)$ distrib.

y sean $\bar{X} = \frac{1}{n} \cdot \sum_{i=1}^n X_i$, $S^2 = \frac{1}{n-1} \cdot \sum_{i=1}^n (X_i - \bar{X})^2$, entonces:

- a) \bar{X} y S^2 son independientes v.a's.
- b) \bar{X} es normal distribuida con media μ y var $\frac{\sigma^2}{n}$
- c) $\frac{(n-1) \cdot S^2}{\sigma^2}$ es χ^2 con $(n-1)$ g.l.

χ^2 , χ^2

$\chi^2_p \rightarrow$ g.l. Normal estándar

a) si Z es $N(0,1)$, entonces $Z^2 \approx \chi^2$

b) Sean $\{X_n\}$ independientes y $X_i \sim \chi^2_{p_i} \Rightarrow \sum_{i=1}^n X_i \sim \chi^2_{\sum_{i=1}^n p_i}$

Una suma de χ^2 's indep. es una χ^2 con $\sum p_i$ g.l.

T student

\longrightarrow se usa para estimar μ si no se conoce σ^2 .

Sean $\{X_n\}$ iid $X_i \sim N(\mu, \sigma^2)$

don $\{x_i\}_{i=1}^n \sim N(\mu, \sigma^2)$

$$\Rightarrow T = \frac{(\bar{X} - \mu)}{\frac{s}{\sqrt{n}}} \text{ es } t\text{-student con } (n-1 = p) \text{ g.l.}$$

la PDF es:

$$f_T(t) = \frac{\Gamma\left(\frac{p+1}{2}\right)}{\Gamma\left(\frac{p}{2}\right)} \cdot \frac{1}{(p\pi)^{1/2}} \cdot \frac{1}{\left(1 + \frac{t^2}{p}\right)^{p+1/2}}$$

Otra forma de obtener una T student es con:

$$\begin{aligned} U &= N(0,1) \\ V &= \chi_p^2 \text{ indep.} \end{aligned} \Rightarrow T = \frac{U}{\sqrt{V/p}}$$

$$\textcircled{1} E(T_p) = 0, p > 1.$$

$$\textcircled{2} \text{Var}(T_p) = \frac{p}{p-2}, p > 2.$$

F \rightarrow usado para comparar variables

Sea $\{y_i\}$ una muestra aleatoria de una población con media μ_y y var σ_y^2 , y sean $\{x_i\}, \mu_x, \sigma_x^2$ definidos análogamente.

$$F = \frac{S_x^2 / \sigma_x^2}{S_y^2 / \sigma_y^2} \quad \begin{matrix} \text{---} & \text{---} \\ \text{---} & \text{---} \end{matrix} \begin{matrix} n-1 \text{ gl.} \\ m-1 \text{ gl.} \end{matrix}$$

la PDF es:

$$f_F(x) = \frac{\Gamma\left(\frac{p+q}{2}\right)}{\Gamma\left(\frac{p}{2}\right) \cdot \Gamma\left(\frac{q}{2}\right)} \cdot \left(\frac{p}{q}\right)^{p/2} \cdot \frac{x^{(p/2)-1}}{\left(1 + \frac{p}{q}x\right)^{(p+q)/2}}$$

$$\textcircled{1} E(F_{n-1, m-1}) = \frac{m-1}{m-3}$$

$$\textcircled{2} \text{ si } X \sim F_{p,q}, \frac{1}{X} \sim F_{q,p}$$

$$\textcircled{3} X \sim t_q, X^2 \sim F_{1,q}$$

Propiedades de estimadores

Propiedades de estimadores

Eficiencia relativa

Sean $\hat{\theta}_1$ y $\hat{\theta}_2$ estimadores insesgados de θ
con $\text{Var}(\hat{\theta}_1) = \sigma_{\hat{\theta}_1}^2$ y $\text{Var}(\hat{\theta}_2) = \sigma_{\hat{\theta}_2}^2$ entonces

$$\text{eff}(\hat{\theta}_1, \hat{\theta}_2) = \frac{\text{Var}(\hat{\theta}_2)}{\text{Var}(\hat{\theta}_1)}$$

Si $\text{eff}(\hat{\theta}_1, \hat{\theta}_2) > 1$, $\hat{\theta}_2$ tiene más varianza luego es preferible $\hat{\theta}_1$.

Consistencia

Sea una muestra de tamaño n , $\hat{\theta}_n$ es consistente si:

$$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) = 1, \quad \hat{\theta}_n \xrightarrow{p \rightarrow \text{tiende en prob.}} \theta$$

Otra forma de verlo es:

Sea $\hat{\theta}_n$ un estimador insesgado de θ . $\hat{\theta}_n$ es consistente si

$$\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0$$

→ \bar{Y}_n es un estimador consistente

i) $\bar{Y}_1 - \bar{Y}_2$ también para $\mu_1 - \mu_2$

ii) $\hat{p}_1 - \hat{p}_2$ también para $p_1 - p_2$

Suficiencia

Sea $\{Y_n\}$ una muestra aleatoria de una distrib.
con parámetro θ , entonces $U = g(Y_1, \dots, Y_n)$ es
suficiente para θ si la distribución condicional Y_1, \dots, Y_n
dado $U=u$ no depende de θ .

Si $P(Y_1, \dots, Y_n | \theta, U=u)$ no depende de θ
⇒ $g(Y_1, \dots, Y_n)$ es suficiente para θ .

Verosimilitud

$$\frac{L(Y_1 \dots Y_n | \theta)}{L(\theta)} = \begin{cases} p_{Y_1 \dots Y_n}(Y_1 \dots Y_n | \theta) & \text{si } Y_i \text{ discreta} \\ f_{Y_1 \dots Y_n}(Y_1 \dots Y_n | \theta) & \text{si } Y_i \text{ continua} \end{cases}$$

Criterio de factorización

Sea U un estimador basado en una muestra aleatoria

$$\text{si } L(\theta) = \underbrace{g(U, \theta)}_{\substack{\downarrow \\ \text{depende de} \\ U \text{ y de } \theta}} \cdot \underbrace{h(Y_1 \dots Y_n)}_{\substack{\downarrow \\ \text{no depende de} \\ \theta}}$$

Teorema de Rao-Blackwell \rightarrow Si se tiene $\hat{\theta}$ insesgado y U suficiente aplicar Rao-Blackwell da el **MVUE**

Sea $\hat{\theta}$ un estimador para θ tal que $\text{Var}(\hat{\theta}) < \infty$
Si U es un estimador suficiente para θ .

$$\text{Sea } \hat{\theta}^* = E(\hat{\theta} | U)$$

$$\begin{aligned} \Rightarrow \bullet E(\hat{\theta}^*) &= E(E(\hat{\theta} | U)) \\ &= E(\hat{\theta}) \\ &= \theta \end{aligned}$$

$$\begin{aligned} \bullet \text{Var}(\hat{\theta}) &= \text{Var}(E(\hat{\theta} | U)) + E(\text{Var}(\hat{\theta} | U)) \\ &= \text{Var}(\hat{\theta}^*) + E(\text{Var}(\hat{\theta} | U)) \geq 0 \end{aligned}$$

$$\text{Var}(\hat{\theta}) \geq \text{Var}(\hat{\theta}^*) \geq 0$$

MVUE \rightarrow estimador insesgado de mínima varianza.