


Recuerde: Sea  $M_n = \frac{1}{n} \sum_{i=1}^n X_i$ ,  $E(M_n) = \mu$ ,  $Var(M_n) = \frac{\sigma^2}{n}$

### Desigualdad de Markov




Si una v.a.  $X \geq 0$ , entonces

$$P(X \geq a) \leq \frac{E(X)}{a}, \quad \forall a > 0$$

### Desigualdad de Chebyshev

Sea  $X$  v.a. con media  $\mu$  y var  $\sigma^2$ , entonces

$$P(|X - \mu| \geq c) \leq \frac{\sigma^2}{c^2}, \quad \forall c > 0.$$




### Ley débil de los grandes números


Sea  $\{X_n\}$  una secuencia de v.a.'s iid con media  $\mu$ .

$\forall \varepsilon > 0$ , se tiene:

$$P(|M_n - \mu| \geq \varepsilon) = P\left(\left|\frac{X_1 + \dots + X_n}{n} - \mu\right| \geq \varepsilon\right) \rightarrow 0, \quad n \rightarrow \infty$$



$n \rightarrow \infty$



### Convergencia en probabilidad

Sea  $\{Y_n\}$  una secuencia de v.a.'s (No necesariamente indep).


y Sea  $a \in \mathbb{R}$ .

Si  $\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(|Y_n - a| \geq \varepsilon) = 0$



Si  $\forall \varepsilon > 0$ ,  $\lim_{n \rightarrow \infty} P(|Y_n - a| < \varepsilon) = 1$

$\Rightarrow Y_n$  converge en probabilidad a 'a'.



## Teorema del límite Central

Sea  $\{X_n\}$  una secuencia de iid v.a.'s con media  $\mu$  y Varianza  $\sigma^2$

$$Z_n = \frac{\left(\sum_{i=1}^n X_i\right) - n \cdot \mu}{\sigma \sqrt{n}}$$

entonces la CDF de  $Z_n$  converge a la CDF N.E.

$$\Phi(z) = \frac{1}{\sqrt{2\pi}} \cdot \int_{-\infty}^z e^{-x^2/2} dx$$

## Aproximaciones basadas en el TLC

Sea  $S_n = \sum_{i=1}^n X_i$  de  $X_i$  iid con media  $\mu$  y var  $\sigma^2$ , para  $n$  grande  $S_n$  se puede tratar como normal así:

$$\left. \begin{aligned} P(S_n \leq C) \\ P\left(Z \leq \frac{C - n\mu}{\sigma\sqrt{n}}\right) \approx \Phi(Z) \end{aligned} \right\} \text{Normalización}$$

## Aproximación de Moivre-Laplace

Una binomial es  $S_n = \sum_{i=1}^n X_i$ , donde cada  $X_i$  es bernoulli iid.

$$E(X_i) = p, \text{ var}(X_i) = p \cdot (1-p).$$

$$P(K \leq S_n \leq L) \approx \Phi\left(\frac{L + \frac{1}{2} - np}{\sqrt{n \cdot p \cdot (1-p)}}\right) - \Phi\left(\frac{K - \frac{1}{2} - np}{\sqrt{n \cdot p \cdot (1-p)}}\right)$$

## Ley fuerte de los grandes números



grandes  $n$

Sea  $\{X_n\}$  iid. con media  $\mu$ , entonces

$$M_n = \frac{\sum_{i=1}^n X_i}{n} \longrightarrow \mu, \text{ con probabilidad 1 o decir:}$$

$$P\left(\lim_{n \rightarrow \infty} \frac{\sum_{i=1}^n X_i}{n} = \mu\right) = 1$$

## Muestreo de una población normal

Sea  $\{X_n\}$  una muestra aleatoria de una  $N(\mu, \sigma^2)$  distrib.

y sean  $\bar{X} = \frac{1}{n} \cdot \sum_{i=1}^n X_i$ ,  $S^2 = \frac{1}{n-1} \cdot \sum_{i=1}^n (X_i - \bar{X})^2$ , entonces:

(a)  $\bar{X}$  y  $S^2$  son independientes v.a's.

(b)  $\bar{X}$  es normal distribuida con media  $\mu$  y var  $\frac{\sigma^2}{n}$

(c)  $\frac{(n-1) \cdot S^2}{\sigma^2}$  es  $\chi^2$  con  $(n-1)$  g.l.

$\chi^2$ ,  $\chi^2$

$\chi_p^2 \rightarrow$  g.l.  $\nearrow$  Normal estándar

(a) si  $Z$  es  $N(0,1)$ , entonces  $Z^2 \sim \chi^2$

(b) Sean  $\{X_n\}$  independientes y  $X_i \sim \chi_{p_i}^2 \Rightarrow \sum_{i=1}^n X_i \sim \chi_{\sum_{i=1}^n p_i}^2$

Una suma de  $\chi^2$  indep. es una  $\chi^2$  con  $\sum p_i$  g.l.

T student

$\longrightarrow$  se usa para estimar  $\mu$  si no se conoce  $\sigma^2$ .

Sean  $\{X_n\}$  iid  $X_i \sim N(\mu, \sigma^2)$

$\Rightarrow T = \frac{(\bar{X} - \mu)}{\frac{S}{\sqrt{n}}}$  es t-student con  $(n-1=p)$  g.l.

la PDF es:

$$f_T(t) = \frac{\Gamma\left(\frac{p+1}{2}\right)}{\Gamma\left(\frac{p}{2}\right)} \cdot \frac{1}{(p\pi)^{1/2}} \cdot \frac{1}{\left(1 + \frac{t^2}{p}\right)^{p+1/2}}$$

Otra forma de obtener una T student es con:

$$U = N(0,1) \quad \Rightarrow \quad T = \frac{U}{\sqrt{V/p}}$$

$$V = \chi_p^2 \text{ indep.}$$



$$V = \chi_p^2 \text{ indep. } \sqrt{V/p}$$

$$\textcircled{\bullet} \bar{E}(T_p) = 0, p > 1.$$

$$\textcircled{\bullet} \text{Var}(T_p) = \frac{p}{p-2}, p > 2.$$

**F**  $\rightarrow$  usado para comparar variables

Sea  $\{y_i\}$  una muestra aleatoria de una población con media  $\mu_y$  y var  $\sigma_y^2$ , y sean  $\{x_i\}, \mu_x, \sigma_x^2$  definidos análogamente.

$$F = \frac{S_x^2 / \sigma_x^2}{S_y^2 / \sigma_y^2} \left[ \begin{array}{l} n-1 \text{ gl.} \\ m-1 \text{ gl.} \end{array} \right]$$

la PDF es:

$$f_F(x) = \frac{\Gamma\left(\frac{p+q}{2}\right)^{p/2} \cdot \left(\frac{p}{q}\right)^{p/2} \cdot \frac{x^{(p/2)-1}}{(1+\frac{p}{q})(\frac{p+q}{2})}}$$

$$\textcircled{1} \bar{E}(F_{n-1, m-1}) = \frac{m-1}{m-3}$$

$$\textcircled{2} \text{ si } X \sim F_{p,q}, \frac{1}{X} \sim F_{q,p}$$

$$\textcircled{3} X \sim t_q, X^2 \sim F_{1,q}$$

## Propiedades de estimadores

### Eficiencia relativa

Sean  $\hat{\theta}_1$  y  $\hat{\theta}_2$  estimadores insesgados de  $\theta$   
 con  $\text{Var}(\hat{\theta}_1) = \sigma_{\hat{\theta}_1}^2$  y  $\text{Var}(\hat{\theta}_2) = \sigma_{\hat{\theta}_2}^2$  entonces

$$efs(\hat{\theta}_1, \hat{\theta}_2) = \frac{\text{Var}(\hat{\theta}_2)}{\text{Var}(\hat{\theta}_1)}$$

Si  $efs(\hat{\theta}_1, \hat{\theta}_2) > 1$ ,  $\hat{\theta}_2$  tiene más varianza luego es preferible  $\hat{\theta}_1$ .

### Consistencia

Sea una muestra de tamaño  $n$ ,  $\hat{\theta}_n$  es consistente si:  
 $n \rightarrow \infty$  tiende a prob.



Sea una muestra de tamaño  $n$ ,  $\hat{\theta}_n$  es consistente si:

$$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) = 1, \quad \hat{\theta}_n \xrightarrow{p \rightarrow \text{tiende en prob.}} \theta$$

Otra forma de verlo es:

Sea  $\hat{\theta}_n$  un estimador insesgado de  $\theta$ .  $\hat{\theta}_n$  es consistente si:

$$\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0$$

→  $\bar{Y}_n$  es un estimador consistente

i)  $\bar{Y}_1 - \bar{Y}_2$  también para  $\mu_1 - \mu_2$

ii)  $\hat{p}_1 - \hat{p}_2$  también para  $p_1 - p_2$

## Suficiencia

Sea  $\{Y_n\}$  una muestra aleatoria de una distrib. con parámetro  $\theta$ , entonces  $U = g(Y_1, \dots, Y_n)$  es suficiente para  $\theta$  si la distribución condicional  $Y_1, \dots, Y_n$  dado  $U=u$  no depende de  $\theta$ .

Si  $P(Y_1, \dots, Y_n | \theta, U=u)$  no depende de  $\theta$   
 $\Rightarrow g(Y_1, \dots, Y_n)$  es suficiente para  $\theta$ .

## Verosimilitud

$$\frac{L(Y_1, \dots, Y_n | \theta)}{L(\theta)} = \begin{cases} P_{Y_1, \dots, Y_n}(Y_1, \dots, Y_n | \theta) & \text{si } Y_i \text{ discreta} \\ f_{Y_1, \dots, Y_n}(Y_1, \dots, Y_n | \theta) & \text{si } Y_i \text{ continua} \end{cases}$$

## Criterio de factorización

Sea  $U$  un estimador basado en una muestra aleatoria

$$\text{Si } L(\theta) = \underbrace{g(U, \theta)}_{\substack{\text{depende de} \\ U \text{ y de } \theta}} \cdot \underbrace{h(Y_1, \dots, Y_n)}_{\substack{\text{no depende de} \\ \theta}}$$

**Teorema de Rao-Blackwell** → Si se tiene  $\hat{\theta}$  insesgado y  $U$  suficiente aplicar Rao-Blackwell da el **MVUE**

Sea  $\hat{\theta}$  un estimador para  $\theta$  tal que  $\text{Var}(\hat{\theta}) < \infty$   
 Si  $U$  es un estimador suficiente para  $\theta$ .

$$\text{Sea } \hat{\theta}^* = E(\hat{\theta} | U)$$

$$\Rightarrow E(\hat{\theta}^*) = E(E(\hat{\theta} | U))$$



$$\Rightarrow \odot E(\hat{\theta}^*) = E(E(\hat{\theta}|U)) \\ = E(\hat{\theta}) \\ = \theta$$

$$\odot \text{Var}(\hat{\theta}) = \text{Var}(E(\hat{\theta}|U)) + E(\text{Var}(\hat{\theta}|U)) \\ = \text{Var}(\hat{\theta}^*) + E(\text{Var}(\hat{\theta}|U)) \geq 0$$

$$\text{Var}(\hat{\theta}) \geq \text{Var}(\hat{\theta}^*) \geq 0$$

**MVUE**  $\longrightarrow$  estimador insesgado de mínima Varianza.

**Método de Momentos**  $\longrightarrow$  para obtener estimadores puntuales de parámetros poblacionales.

el método de momentos usa los momentos de una distribución de prob. para generar a partir de allí un sistema de eqns. de donde por solución salga el estimador para el o los parámetros.

$M_k$  es el  $k$ -ésimo momento de una v.a.

$$M_k = E(X^k)$$

$\longrightarrow$  momentos poblacionales

$m_k$  es el estimador natural de  $M_k$  que es:

$$m_k = \frac{1}{n} \cdot \sum_{i=1}^n (y_i)^k = E(y^k) \rightsquigarrow \text{momentos muestrales}$$

La idea es entonces solucionar las eqns para los momentos poblacionales y sus correspondientes muestrales.

las eqns. son:  $\hat{M}_k = m_k \quad k=1, \dots, (t) \rightarrow \# \text{ de parámetros a estimar}$

La idea aquí es que los  $m_k$  son buenos estimadores de los  $M_k$  y se pueden igualar y solucionar.

**Método de máxima Verosimilitud**